

Machine Learning : Introduction

D. Cornu

M2-P2N Automne - 2019

Tous les supports de cours (slides, codes, exercices, corrections, ...) sont disponibles sur GitHub et seront mis à jour progressivement :

[Deyht/ML_M2](#)

Quelques commandes utiles :

```
sudo apt-get install git
```

```
git clone https://github.com/Deyht/ML_M2
```

```
git pull
```

Pour ne pas risquer de perdre votre travail en cas de mise à jour copiez ces fichiers dans un autre répertoire !

Références utiles pour réviser ou aller plus loin

Stephen Marsland. **Machine Learning an Algorithmic Perspective**. Chapman and Hall/Crc, 2015. Pédagogique, assez complet et exemples de codes en Python

G. James, D. Witten, T. Hastie et R. Tibshirani .**An Introduction to Statistical Learning with applications in R (ISLR)**. Springer, 2013. Approche plus statistique du machine learning, exemples en R

Christopher M. Bishop. **Pattern Recognition and Machine Learning**. Springer, 2011. Très mathématique, contient toute la théorie nécessaire

Cours 1 : Introduction des concepts du Machine Learning et introduction d'algorithmes classiques

Cours 2 à 4 : Introduction sur les réseaux de neurones artificiels simples (1 couche) et implémentation guidée, puis réseaux multi-couches et implémentation matricielle ...

Cours 5 : Programmation GPU - CUDA (kernels et cuBLAS)

Problématiques :

- Traiter un nombre toujours plus grand de données
- Extraire de l'information difficilement visualisable (> 2 dimensions)
- Reproduire l'intelligence de manière artificielle

Problématiques :

- Traiter un nombre toujours plus grand de données
- Extraire de l'information difficilement visualisable (> 2 dimensions)
- Reproduire l'intelligence de manière artificielle

Solution possible : Machine learning

Objectif :

→ **apprendre à un ordinateur à extraire une information statistique et à s'adapter à celle-ci via un processus d'apprentissage.**

Question : Comment définir "l'apprentissage" ?

Définition de l'apprentissage

« Acquérir la connaissance d'une chose par l'exercice de l'intelligence, de la mémoire, des mécanismes gestuels appropriés, etc. »

** Trésor de la Langue Française informatisé TLFi*

Définition de l'apprentissage

« Acquérir la connaissance d'une chose par l'exercice de l'intelligence, de la mémoire, des mécanismes gestuels appropriés, etc. »

** Trésor de la Langue Française informatisé TLFi*

D'une manière générale, on peut représenter l'apprentissage animal avec trois capacités :

Définition de l'apprentissage

« Acquérir la connaissance d'une chose par l'exercice de l'intelligence, de la mémoire, des mécanismes gestuels appropriés, etc. »

** Trésor de la Langue Française informatisé TLFi*

D'une manière générale, on peut représenter l'apprentissage animal avec trois capacités :

- **Se souvenir**
- **S'adapter**
- **Généraliser**

Définition de l'apprentissage

« Acquérir la connaissance d'une chose par l'exercice de l'intelligence, de la mémoire, des mécanismes gestuels appropriés, etc. »

** Trésor de la Langue Française informatisé TLFi*

D'une manière générale, on peut représenter l'apprentissage animal avec trois capacités :

- **Se souvenir** - **S'adapter** - **Généraliser**

Savoir **reconnaître une situation** dans laquelle on a déjà été (**avoir vu ces données**) et se **souvenir** de notre **réaction** (**avoir donné cette sortie**) et déterminer si celle-ci était **appropriée** (**solution correcte**).

Dernière étape du processus : la **généralisation** → trouver des similitudes entre les situations et supposer que des solutions adaptées dans certains cas peuvent être appliquées à d'autres.

Pour parler **d'intelligence** il manque encore :

- **Le raisonnement**

(Capacité à poser un problème)

- **La déduction logique**

(Capacité à ordonner des propositions qui s'impliquent)

Dernière étape du processus : la **généralisation** → trouver des similitudes entre les situations et supposer que des solutions adaptées dans certains cas peuvent être appliquées à d'autres.

Pour parler **d'intelligence** il manque encore :

- **Le raisonnement**

(Capacité à poser un problème)

- **La déduction logique**

(Capacité à ordonner des propositions qui s'impliquent)

Nécessite ce qu'on appelle le **symbolic processing** → représentation par des symboles qui varient dans le temps ou selon le contexte.

**Le machine learning "classique" reste une représentation
Subsymbolic.**

Types d'apprentissage

Supervisé

Apprend à partir d'un **échantillon d'entraînement** qui contient des exemples ainsi que les réponses associées. L'algorithme tente de généraliser suite à un entraînement.

Renforcé

Mélange des méthodes supervisées et non supervisées. Nécessite un échantillon d'entraînement avec les réponses mais **aucune indication** n'est donnée sur **la manière de s'améliorer**.

Non Supervisé





Les réponses ne sont pas fournies, l'algorithme cherche **les similitudes** entre les données qui lui sont fournies pour former **des catégories**. L'approche statistique donne des estimations de densité.

Evolutionnaire

Inspiré des organismes biologiques qui s'adaptent pour **maximiser leurs chances de survies**. On représente alors la chance de survie comme la proximité à la solution attendue.


Apprentissage supervisé : Régression

Retrouver une fonction mathématique qui se rapproche le plus d'un ensemble de points




Apprentissage supervisé : Classification

Décider à partir d'un vecteur d'entrée une des N classes associées.
Difficulté : déterminer la forme des frontières. Parfois des objets n'appartiennent pas à une classe définie (novelty détection)




Apprentissage non supervisé : Clustering

Trouver des groupes dans les données selon une stratégie prédéfinie (par exemple la distance géométrique) sans connaître à l'avance ni le nombre de groupes ni aucune solution pour aucun des objets.



Autres application du machine learning


Prédiction de série temporelle



Compression de données



Reconnaissance d'images



...

Maintenant que l'on sait ce dont le ML est capable comment l'utiliser ?



Exemple de frameworks

TensorFlow™[Install](#)[Develop](#)[Community](#)[API r1.11 ▾](#)[Ecosystem ▾](#)

Search

[GITHUB](#)

API r1.11

[PYTHON](#)[JAVASCRIPT](#)[C++](#)[JAVA](#)[MORE...](#)

Overview

Implementations

TensorFlow.js

Go ☒

Haskell ☒

> Community Supported

Ecosystem

Hub

API Documentation



TensorFlow has APIs available in several languages both for constructing and executing a TensorFlow graph. The Python API is at present the most complete and the easiest to use, but other language APIs may be easier to integrate into projects and may offer some performance advantages in graph execution.

A word of caution: the APIs in languages other than Python are not yet covered by the [API stability promises](#).

- [Python](#)
- [JavaScript](#)
- [C++](#)
- [Java](#)
- [Go](#)
- [Swift \(Early Release\)](#)

We encourage the community to develop and maintain support for other languages with the [approach recommended by the TensorFlow maintainers](#). For example, see the bindings for:

- [C#](#),
- [Haskell](#),
- [Julia](#),
- [Ruby](#),
- [Rust](#), and
- [Scala](#).

We also provide the C++ API reference for TensorFlow Serving:

- [TensorFlow Serving](#)

Exemple de frameworks

```
from __future__ import print_function

import tensorflow as tf
import numpy
import matplotlib.pyplot as plt
rng = numpy.random

# Parameters
learning_rate = 0.01
training_epochs = 1000
display_step = 50

# Training Data
train_X = numpy.asarray(
[3.3,4.4,5.5,6.71,6.93,4.168,9.779,6.182,7.59,
2.167,7.042,10.791,5.313,7.997,5.654,9.27,3.1])
train_Y = numpy.asarray(
[1.7,2.76,2.09,3.19,1.694,1.573,3.366,2.596,2.53,
1.221,2.827,3.465,1.65,2.904,2.42,2.94,1.3])
n_samples = train_X.shape[0]

# tf Graph Input
X = tf.placeholder("float")
Y = tf.placeholder("float")

# Set model weights
W = tf.Variable(rng.randn(), name="weight")
b = tf.Variable(rng.randn(), name="bias")

# Construct a linear model
pred = tf.add(tf.multiply(X, W), b)
# Mean squared error
cost = tf.reduce_sum(tf.pow(pred-Y, 2))/(2*n_samples)

# Gradient descent
optimizer = tf.train.GradientDescentOptimizer(
learning_rate).minimize(cost)
init = tf.global_variables_initializer()

# Start training
with tf.Session() as sess:

    # Run the initializer
    sess.run(init)

    # Fit all training data
    for epoch in range(training_epochs):
        for (x, y) in zip(train_X, train_Y):
            sess.run(optimizer, feed_dict={X: x, Y: y})
```

```
# Display logs per epoch step
if (epoch+1) % display_step == 0:
    c = sess.run(cost, feed_dict={X: train_X
    , Y:train_Y})
    print("Epoch:", '%04d' % (epoch+1), "
    cost=", "{:.9f}".format(c), \
    "W=", sess.run(W), "b=", sess.run(b))

print("Optimization Finished!")
training_cost = sess.run(cost, feed_dict={X:
train_X, Y: train_Y})
print("Training cost=", training_cost, "W=",
sess.run(W), "b=", sess.run(b), '\n')

plt.plot(train_X, train_Y, 'ro', label='Original
data')
plt.plot(train_X, sess.run(W) * train_X + sess.
run(b), label='Fitted line')
plt.legend()
plt.show()


test_X = numpy.asarray([6.83, 4.668, 8.9, 7.91,
5.7, 8.7, 3.1, 2.1])
test_Y = numpy.asarray([1.84, 2.273, 3.2, 2.831,
2.92, 3.24, 1.35, 1.03])

print("Testing... (Mean square loss Comparison)")

testing_cost = sess.run(
tf.reduce_sum(tf.pow(pred - Y, 2)) / (2 *
test_X.shape[0]),
feed_dict={X: test_X, Y: test_Y}) # same
function as cost above
print("Testing cost=", testing_cost)
print("Absolute mean square difference:",
abs(
training_cost - testing_cost))

plt.plot(test_X, test_Y, 'bo', label='Testing
data')
plt.plot(train_X, sess.run(W) * train_X + sess.
run(b), label='Fitted line')
plt.legend()
plt.show()
```

Exemple de frameworks



C++

- array_ops
- candidate_sampling_ops
- control_flow_ops
- core
- data_flow_ops
- image_ops
- io_ops
- logging_ops
- math_ops
- nn_ops
- no_op
- parsing_ops
- random_ops
- sparse_ops
- state_ops
- string_ops
- training_ops
- user_ops
- Namespaces

Guides

The Basics

Let's start with a simple example that illustrates graph construction and execution using the C++ API.

```
// tensorflow/cc/example/example.cc

#include "tensorflow/cc/client/client_session.h"
#include "tensorflow/cc/ops/standard_ops.h"
#include "tensorflow/core/framework/tensor.h"

int main() {
  using namespace tensorflow;
  using namespace tensorflow::ops;
  Scope root = Scope::NewRootScope();
  // Matrix A = [ 3 2; -1 0 ]
  auto A = Const(root, { {3.f, 2.f}, {-1.f, 0.f} });
  // Vector b = [ 3 5 ]
  auto b = Const(root, { {3.f, 5.f} });
  // v = A*b
  auto v = MatMul(root.WithOpName("v"), A, b, MatMul::TransposeB(true));
  std::vector<Tensor> outputs;
  ClientSession session(root);
  // Run and fetch v
  TF_CHECK_OK(session.Run({v}, &outputs));
  // Expect outputs[0] == [19; -3]
  LOG(INFO) << outputs[0].matrix<float>();
  return 0;
}
```

Place this example code in the file `tensorflow/cc/example/example.cc` inside a clone of the TensorFlow [github repository](#). Also place a `BUILD` file in the same directory with the following contents:

```
load("//tensorflow:tensorflow.bzl", "tf_cc_binary")

tf_cc_binary(
  name = "example",
  srcs = ["example.cc"],
  deps = [
```

Contents

The Basics

- Graph Construction
- Scope
- Operation Constructors
- Constants
- Graph Execution

Exemple de frameworks

```
# Parameters
TRAINING_SIZE <- 50000
DIGITS <- 2
MAXLEN <- DIGITS + 1 + DIGITS
charset <- c(0:9, "+", "_")
char_table <- learn_encoding(charset)
examples <- generate_data(size = TRAINING_SIZE,
  digits = DIGITS)
x <- array(0, dim = c(length(examples$questions),
  MAXLEN, length(char_table)))
y <- array(0, dim = c(length(examples$questions),
  DIGITS + 1, length(char_table)))

for(i in 1:TRAINING_SIZE){
  x[i,,] <- encode(examples$questions[i], char_table)
  y[i,,] <- encode(examples$results[i], char_table)
}

indices <- sample(1:TRAINING_SIZE, size = TRAINING_SIZE)
x <- x[indices,,]
y <- y[indices,,]
# Explicitly set apart 10% for validation data that
# we never train over
split_at <- trunc(TRAINING_SIZE/10)
x_val <- x[1:split_at,,]
y_val <- y[1:split_at,,]
x_train <- x[(split_at + 1):TRAINING_SIZE,,]
y_train <- y[(split_at + 1):TRAINING_SIZE,,]

print('Training Data:')
print(dim(x_train))
print(dim(y_train))
print('Validation Data:')
print(dim(x_val))
print(dim(y_val))

# Training
HIDDEN_SIZE <- 128
BATCH_SIZE <- 128
```

```
LAYERS <- 1

model <- keras_model_sequential()

model %>%
  layer_lstm(HIDDEN_SIZE, input_shape=c(MAXLEN,
    length(char_table))) %>%
  layer_repeat_vector(DIGITS + 1)

for(i in 1:LAYERS)
  model %>% layer_lstm(HIDDEN_SIZE, return_sequences
    = TRUE)

model %>%
  time_distributed(layer_dense(units = length(char_
    table))) %>%
  layer_activation("softmax")

model %>% compile(
  loss = "categorical_crossentropy",
  optimizer = "adam",
  metrics = "accuracy"
)
summary(model)

# Fitting loop
model %>% fit(
  x = x_train,
  y = y_train,
  batch_size = BATCH_SIZE,
  epochs = 70,
  validation_data = list(x_val, y_val)
)

# Predict for a new observation
new_obs <- encode("55+22", char_table) %>%
  array(dim = c(1,5,12))
result <- predict(model, new_obs)
result <- result[1,,]
decode(result, char_table)
```

Quelle approche choisir ?

Utiliser des frameworks

- Beaucoup de supports (Guides, aide au debug, ...)
- Souvent déjà parallélisé
- Performant rapidement
- Mis à jour sans votre intervention (gain de performance dans le temps sans changer de code)

"Ouvrir la boîte"

- Meilleure compréhension des mécanismes
- Contrôle plus fin, et niveau d'optimisation contrôlé
- Indépendant du maintien d'une librairie
- Capable à terme d'utiliser les différents frameworks facilement

Exemple d'algorithmes supervisé : SVM

Description : Le Support Vector Machine est un algorithme supervisé qui sert à faire de la classification.

Objectif : Généraliser les propriétés propres à certaines classes d'objets pré-établies avec un nombre de dimensions arbitraire.

Méthode : trouver les points les plus proches de la séparation étudiée qui définiront les "supports". Une fois ces points établis, l'algorithme cherche la **séparation linéaire** qui minimise la somme des distances entre les points des différentes classes. Pour cela, il cherche notamment à **maximiser la surface** autour de cette séparation qui ne contient aucun des "supports".

Mémoire : L'algorithme conserve la mémoire de cette classification via la pente et l'ordonnée à l'origine de cette séparation linéaire. → Capable de généraliser.

Support Vector Machine illustré

Mise en pratique : L'algorithme k-means

Description : Cet algorithme est non-supervisé et sert à faire du clustering.

Objectif : Trouver des groupes dans des données avec un nombre de dimensions arbitraire selon une méthode géométrique.

Méthode : définir un nombre "k" de centres (définie le nombre de groupes maximum). Pour chacun des points il trouve le centre le plus proche selon une distance géométrique. Les centres sont ensuite déplacés vers le centre de gravité du groupe de points qui leur correspond. Cette opération est répétée jusqu'à ce que les centres ne bougent plus.

Mémoire : L'algorithme conserve la mémoire des clusters en retenant la position des différents centres. → Capable de généraliser.

k-means clustering illustré

Boucle principale : jusqu'à ce que les centres ne bougent plus

- **Phase d'identification** : boucle sur les points
 - Calcul de la distance aux différents centres (k)
 - Associer le point en cours au centre le plus proche
- **Phase de mise à jour** : Boucle sur les centres
 - Calcul du barycentre du cluster défini précédemment
 - Repositionner le centre à la place du barycentre

k-means : Exercice - Coder le k-means

Données : Vous disposez de fichiers de données *kmeans_input_file.dat*, ainsi que du code python ayant servi pour leur génération.

Code : un code incomplet est fourni, la lecture du fichier d'entrée y est intégrée, ainsi qu'une fonction de calcul de distance. Plusieurs variables utiles sont fournies mais toutes les variables nécessaires n'ont pas été déclarées.

Points clés :

- Identifier les variables supplémentaires dont vous aurez besoin.
- Bien identifier les différentes boucles, et les coder.
- Prendre le temps de réfléchir au moyen de trouver la distance minimum.
- Trouver comment interrompre la boucle principale intelligemment.

Résultats : Un outil de visualisation est proposé *kmeans_visual.py*